

Analiza danych zbioru Iris

Numer indeksu: 119069
Grupa: PS2

Wstęp

Celem niniejszego zadania jest przeprowadzenie klasyfikacji zbioru danych *Iris* przy użyciu algorytmu **KNN** (K-Nearest Neighbors). Problem polega na automatycznym rozpoznawaniu jednego z trzech gatunków irysa (*Setosa*, *Versicolor*, *Virginica*) na podstawie czterech cech fizycznych: długości i szerokości działki kielicha oraz płatków. Do realizacji zadania wykorzystano język Python oraz bibliotekę `scikit-learn`.

Krótką analiza danych (EDA)

Zbiór danych *Iris* składa się ze **150 próbek** kwiatów, podzielonych po równo na trzy gatunki: *Setosa*, *Versicolor* oraz *Virginica*. Każdy kwiatek opisany jest przez cztery cechy:

1. Długość działki kielicha (sepal length)
2. Szerokość działki kielicha (sepal width)
3. Długość płatka (petal length)
4. Szerokość płatka (petal width)

	sepal length	sepal width	petal length	petal width
count	150.000000	150.000000	150.000000	150.000000
mean	5.843333	3.054000	3.758667	1.198667
std	0.828066	0.433594	1.764420	0.763161
min	4.300000	2.000000	1.000000	0.100000
25%	5.100000	2.800000	1.600000	0.300000
50%	5.800000	3.000000	4.350000	1.300000
75%	6.400000	3.300000	5.100000	1.800000
max	7.900000	4.400000	6.900000	2.500000

Wnioski z analizy statystycznej: Na podstawie statystyk opisowych (funkcja `describe()`) zauważono, że cechy mają różne zakresy wartości. Przykładowo, średnia długość kielicha wynosi ok. **5.8 cm**, podczas gdy średnia szerokość płatków to tylko **1.2 cm**.

Dlaczego to ważne? Ponieważ algorytm KNN bazuje na obliczaniu odległości między punktami, cechy o większych wartościach liczbowych mogłyby "zdominować" te o mniejszych. Aby temu zapobiec i dać każdej cenie taką samą wagę, zastosowano **skalowanie danych** (`StandardScaler`), które sprowadziło wszystkie wartości do wspólnej skali.

Opis algorytmu i parametrów

W projekcie wykorzystano algorytm **K-Nearest Neighbors (KNN)**, czyli algorytm "k-najbliższych sąsiadów". Jest to jedna z najprostszych metod klasyfikacji, która nie buduje skomplikowanego modelu matematycznego, lecz opiera się na zapamiętywaniu danych treningowych.

Jak to działa? Gdy model otrzymuje nowy, nieznany kwiatek, oblicza jego odległość od wszystkich kwiatków, które już zna. Następnie wybiera **k** najbliższych sąsiadów i przypisuje nową próbkę do tej grupy, która dominuje w tym sąsiedztwie.

Wybrane parametry:

- **Liczba sąsiadów (k):** Przyjęto wartość **k = 3**. Jest to wartość optymalna dla małych zbiorów, pozwalająca na stabilną klasyfikację przy jednoczesnym unikaniu "remisów" (dzięki liczbie nieparzystej).
 - **Preprocessing:** Dane zostały poddane **standaryzacji**, aby każda cecha (np. szerokość płatków i długość kielicha) miała taki sam wpływ na obliczaną odległość.
-

Wyniki i metryki

W tej sekcji przedstawiono wyniki klasyfikacji uzyskane na zbiorze testowym (30 próbek).

Wiersz **Accuracy** zawiera puste komórki w kolumnach Precision i Recall, ponieważ jest to wskaźnik ogólny dla całego modelu, a nie dla pojedynczych klas. Globalne uśrednione wartości tych miar znajdują się w wierszach *Macro avg* i *Weighted avg*.

Interpretacja metryk:


- **Accuracy (Dokładność):** Wynosi **1.00**, co oznacza, że 100% próbek testowych zostało zaklasyfikowanych poprawnie.
- **Precision (Precyzja):** Określa, jak wiarygodne są wskazania modelu dla konkretnej klasy (brak błędów typu *False Positive*).

- **Recall (Czułość):** Mówi o zdolności modelu do wykrycia wszystkich przedstawicieli danej klasy (brak błędów typu *False Negative*).
- **F1-Score:** Średnia harmoniczna precyzji i czułości, potwierdzająca stabilność modelu dla każdego gatunku.

Klasa	Precision	Recall	F1-score	Support
Iris-setosa	1.00	1.00	1.00	10
Iris-versicolor	1.00	1.00	1.00	9
Iris-virginica	1.00	1.00	1.00	11
Accuracy			1.00	30
Macro avg	1.00	1.00	1.00	30
Weighted avg	1.00	1.00	1.00	30

Wizualizacja t-SNE

W celu lepszego zrozumienia struktury danych oraz wyników klasyfikacji, zastosowano algorytm **t-SNE** (*t-distributed Stochastic Neighbor Embedding*). Pozwolił on na zredukowanie czterech wymiarów cech do dwóch, co umożliwiło prezentację danych na wykresie płaskim.



Interpretacja wykresu: Na powyższej wizualizacji można zaobserwować trzy wyraźne skupiska punktów, odpowiadające trzem gatunkom irysów:

- **Gatunek Setosa** (zazwyczaj klastry najbardziej oddalone) tworzy wyraźnie odseparowaną grupę, co tłumaczy, dlaczego model klasyfikuje go bezbłędnie.
- **Gatunki Versicolor i Virginica** leżą bliżej siebie, a ich obszary niemal się stykają. To sugeruje, że ich cechy fizyczne są do siebie bardziej zbliżone, jednak dzięki zastosowaniu skalowania i algorytmu KNN, model był w stanie poprawnie wyznaczyć granice między nimi.

Podsumowanie i wnioski

Przeprowadzona analiza wykazała, że algorytm **KNN** doskonale radzi sobie z klasyfikacją gatunków irysów, osiągając **100% skuteczności** na zbiorze testowym.

Kluczowe wnioski:

- **Wpływ preprocessingu:** Zastosowanie **StandardScaler** było kluczowe, aby różnice w centymetrach między cechami (np. długość płatków vs. szerokość kielicha) nie zaburzyły pracy algorytmu.
- **Dobór parametrów:** Parametr $K=3$ okazał się wystarczający do stabilnej klasyfikacji, co potwierdziły wysokie wartości metryk *Precision* i *Recall*.
- **Separacja klas:** Wizualizacja t-SNE pokazała, że zbiór *Iris* jest liniowo lub prawie liniowo separowalny (szczególnie gatunek *Setosa*), co czyni go idealnym materiałem do nauki klasyfikacji.