

Analiza danych zbioru Heart Disease

Numer indeksu: 119069

Grupa: PS2

Wstęp i Opis Algorytmu

Zgodnie z przydziałem do grupy, do przeprowadzenia klasyfikacji pacjentów pod kątem chorób serca wybrano algorytm Drzew Decyzyjnych (Decision Tree Classifier).

Zrozumienie i działanie algorytmu: Drzewo decyzyjne to algorytm uczenia nadzorowanego, który tworzy model przypominający strukturę drzewa (graf). Działa on poprzez sekwencyjne dzielenie zbioru danych na mniejsze, coraz bardziej homogeniczne (jednorodne) podgrupy. W każdym "węźle" drzewa algorytm zadaje pytanie o konkretną cechę danych (np. "Czy wiek > 55 lat?"). Na podstawie odpowiedzi (Tak/Nie) dane kierowane są do odpowiednich odgałęzień, aż trafią do "liścia", który reprezentuje ostateczną decyzję lub klasę (w naszym przypadku: zdrowy lub chory).

Algorytm szuka optymalnych podziałów, minimalizując tzw. "zanieczyszczenie" (ang. impurity) w grupach wynikowych. W eksperymentach badano wpływ następujących parametrów na jakość klasyfikacji:

- **max_depth** (Maksymalna głębokość drzewa): Parametr ten ogranicza wysokość drzewa. Jest kluczowy dla kontroli overfittingu (przeuczenia). Zbyt głębokie drzewo uczy się szumu i specyfiki danych treningowych "na pamięć", tracąc zdolność do generalizacji na nowych danych.
- **criterion** (Kryterium podziału): Funkcja mierząca jakość podziału. Najczęściej stosowane to 'gini' (indeks Gini) oraz 'entropy' (pozyskiwanie informacji).

Analiza zbioru danych (EDA)

Wstępna analiza wykazała, że zbiór danych składa się z 303 rekordów (pacjentów). Poniżej przedstawiono wyniki analizy rozkładu zmiennych oraz struktury brakujących danych.

2.1. Analiza brakujących danych Użyto funkcji **check_missing_data** z modułu **data_loader.py** do identyfikacji braków. Analiza wykazała brakujące wartości w dwóch kolumnach:


- **ca**: 4 braki.
- **thal**: 2 braki.

```
# Sposób radzenia sobie z brakami: Imputacja mediana
```

```
X = X.fillna(X.median())
```


Łącznie zidentyfikowano 6 brakujących wartości, co stanowi około 2% całego zbioru. Ze względu na małą liczbę braków, zdecydowano się na ich imputację medianą, aby uniknąć usuwania całych wierszy i zachować cenne dane o pozostałych cechach tych pacjentów. Mediana jest wyborem bezpiecznym, ponieważ jest odporna na ewentualne wartości odstające w danych.

2.2. Rozkład zmiennej celowej (Diagnoza) Zmienna celowa (diagnoza) została przekształcona w postać binarną: wartość 0 oznacza brak choroby (zdrowy), natomiast wartości 1-4 z oryginalnego zbioru oznaczono jako 1 (chory). Rozkład tych klas przedstawiono na wykresie:



Wniosek: Zbiór danych jest stosunkowo dobrze zbalansowany. Liczba osób chorych (139) jest zbliżona do liczby osób zdrowych (164), co jest korzystne dla procesu uczenia modelu klasyfikacji i zapobiega faworyzowaniu jednej klasy przez algorytm.

2.3. Rozkład zmiennej ciągłej (Wiek) Przeprowadzono analizę rozkładu wieku pacjentów, aby lepiej zrozumieć charakterystykę badanej grupy. Wynik przedstawiono na histogramie z nałożoną krzywą gęstości:



Wniosek: Rozkład wieku zbliżony jest do rozkładu normalnego (z lekką asymetrią lewostronną), z najliczniejszą reprezentacją pacjentów w przedziale od 50 do 60 lat. Jest to grupa podwyższonego ryzyka kardiologicznego, co uzasadnia obecność chorób serca w zbiorze.

2.4. Przygotowanie danych kategorycznych Wiele cech w zbiorze to dane kategoryczne (np. **cp** - typ bólu, **thal** - talasemia, **ca** - liczba naczyń krwionośnych). Algorytm Drzewa Decyzyjnego w bibliotece **sklearn** wymaga danych numerycznych. W związku z tym zastosowano technikę One-Hot Encoding (używając funkcji **pd.get_dummies** w Pythonie), która zamienia każdą kategorię na osobną kolumnę z wartościami binarnymi (0 lub 1). Pozwoliło to na poprawne przeprowadzenie obliczeń matematycznych przez algorytm.

```
# Sposób radzenia sobie z danymi kategorycznymi: One-Hot Encoding
```

```
cat_cols = ['cp', 'restecg', 'slope', 'thal', 'ca']
```

```
X_encoded = pd.get_dummies(X, columns=cat_cols, drop_first=True)
```

Przeprowadzone eksperymenty i wyniki

W ramach eksperymentów przetestowano wpływ parametru **max_depth** (maksymalna głębokość drzewa) na jakość klasyfikacji. Wykorzystano cztery wartości: 2, 3, 5 oraz 10. Jakość modeli oceniono za pomocą celności (Accuracy) oraz krzywej ROC i wskaźnika AUC (Area Under the Curve - jak dobrze model potrafi rozróżniać dwie grupy).


```
--- Running experiments ---
```

```
Deep: 2 | Accuracy: 0.72 | AUC: 0.78
```

```
Deep: 3 | Accuracy: 0.72 | AUC: 0.85
```

Deep: 5 | Accuracy: 0.79 | AUC: 0.80

Deep: 10 | Accuracy: 0.79 | AUC: 0.78



3.1. Interpretacja krzywej ROC i wskaźnika AUC Krzywa ROC (Receiver Operating Characteristic) obrazuje zdolność modelu do rozróżniania klas. Im bliżej lewego górnego rogu znajduje się krzywa (wyższe AUC), tym lepszy jest model.

- Najwyższą wartość AUC (0.85) uzyskano dla drzewa o głębokości 3. Oznacza to, że to drzewo najlepiej radzi sobie z zachowaniem balansu między wykrywaniem chorych (True Positive Rate) a unikaniem błędnych alarmów (False Positive Rate).
- Modele o większej głębokości (5 i 10) uzyskały nieco niższe wartości AUC (odpowiednio 0.80 i 0.78), co sugeruje, że zbyt szczegółowe drzewo zaczyna tracić ogólną zdolność do poprawnej klasyfikacji na nowych danych.

3.2. Wpływ parametru **max_depth** na jakość (Wnioski) Analiza wyników pozwala na wyciągnięcie następujących wniosków:

1. Zjawisko Overfittingu: Choć celność (Accuracy) wzrosła z 0.72 do 0.79 przy przejściu z głębokości 3 na 5, to wskaźnik AUC spadł. Świadczy to o tym, że głębsze drzewa

zaczynają zbyt mocno dopasowywać się do specyficznych cech zbioru treningowego, co jest sygnałem lekkiego przeuczenia.

2. Optymalny wybór: Za najbardziej zbalansowany model uznano drzewo o głębokości 3. Zapewnia ono wysoką wartość AUC (0.85) przy zachowaniu prostoty modelu, co ułatwia jego interpretację przez lekarza (krótsza ścieżka decyzji).
3. Podsumowanie algorytmu: Drzewa decyzyjne okazały się skutecznym narzędziem w analizie medycznej. Dzięki wizualizacji ROC udowodniono, że proste modele (mała głębokość) często radzą sobie lepiej z uogólnianiem wiedzy niż modele bardzo złożone.